

一句话总结

给定一个基本的预训练语言模型和sequence-level oracle function（指示是否满足规则），通过训练辅助模型NADO，把序列级规则分解为token级指导，引导模型进行可控文本生成。

Oracle Function: A function is a subprogram that is used to return a single value. [Site Unreachable](#)理解为一个0-1判别函数，相当于是reward model（基于规则）；

文章主要方法是把一个sequence-level信号分解为token-level的guidance信号；

启发：我们的setting是序列决策，从最终的结果的reward信号，如何分解得到过程的reward信号；

核心

- 基于NeurAlly-Decomposed Oracle (NADO) 提出了**可控的**自回归生成模型；
- pre-trained base language model + sequence-level boolean oracle function -> **oracle function** into token-level guidance to steer the base model in text generation；
- token-level指导：从一个base model的数据中进行采样，训练了一个辅助模型NADO；
- 把可控生成问题定义为：基于后验正则化的优化问题。得到**解析最优解**，用来在token-level指导模型的可控生成；
- 对于NADO的近似的质量如何影响最终可控生成的结果进行分析，做了2个任务的实验：
 - text generation with lexical constraints 具有词汇约束的文本生成；
 - machine translation with formality control 带有形式控制的机器翻译；

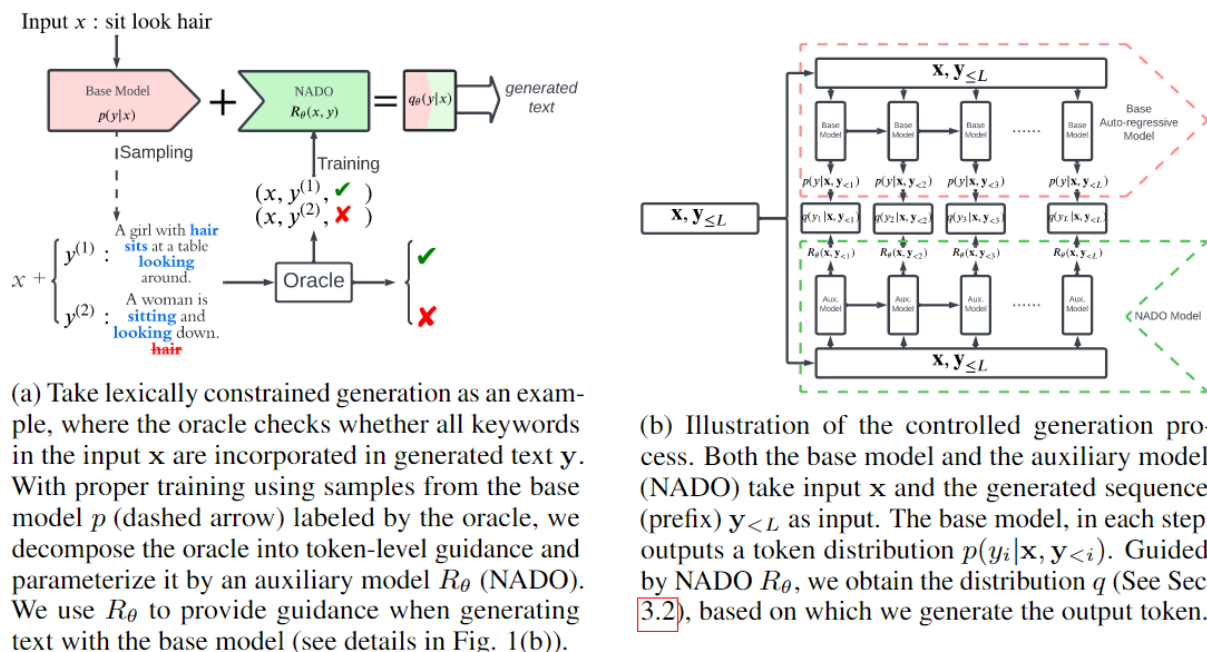


Figure 1: Illustration of pipeline incorporating NADO (left) and model architecture (right).

左图：NADO的训练，从一个base model的生成中进行采样，由一个sequence-level的判别器产生监督信号；base-model在这个过程中不需要fine-tuning；

右图：decompose the sequence-level oracle into token-level guidance, such that when generating the i -th token in the output sequence given the prefix, instead of sampling from the base model, we modify the probability distribution of the output token based on the token-level guidance.

- 把sequence-level规则分解为**token-level的指导**，最终的每个token的生成由base-model + guidance的分布决定；
- base-model + guidance的过程后面再看；

Intro

可控生成

- 要求模型的输出遵循sequence-level的属性：
 - 由一系列规则定义（譬如语法规则）；
 - 由某个抽象概念定义（譬如文风）；
- 现有工作
 - 基于搜索算法的词汇约束的算法，不能应用于风格写作任务；
 - 训练辅助模型（用来微调模型，或者需要外部标记数据），无理论保证，或者成本高；
 - 使用KL-adaptive分布策略来近似一个energy-based model；（粒度太粗？）
- 实验
 - 词汇约束生成 (LCG) 任务：oracle 是一个基于规则的关键字检查器；

- 形式控制的机器翻译任务：提供了一个形式预言机来预测句子是否正式，目标是引导模型生成形式翻译；
- 后处理
 - 可控文本生成的方法归为三大类：fine-tuning, refactor/retraining and post-processing；
 - 后处理的主要步骤：修改decoding算法（如beam search），通过辅助模型指导生成；
 - 辅助模型：PPLM, GeDi, DEXPERTS, FUDGE, 要么需要外部token-level oracle 指导，要么需要辅助标记数据集来训练辅助模型；用于训练辅助模型的数据分布与所训练的模型的分布不同，导致生成质量下降；

方法

- 文章的主要方法就是提出NADO，这是一个近似的辅助模型，得到token-level的指导；
- we discuss 1) the formulation to decompose the sequence-level oracle function into token-level guidance; 2) the formulation to incorporate the token-level guidance into the base model to achieve control; 3) the approximation of the token-level guidance using NADO; 4) a theoretical analysis of the impact of NADO approximation to the controllable generation results; and 5) the training of NADO.
- 非常重要的部分！

概念

- base-model p ;
- 指示函数 C ;
- 要得到一个token-level distribution $q^*(y_i | \mathbf{x}, \mathbf{y}_{<i})$ ，满足：
 1. $q^*(\mathbf{y} | \mathbf{x}) = \prod_i q^*(y_i | \mathbf{x}, \mathbf{y}_{<i})$, i.e., q^* can be treated as an auto-regressive model.
 2. $q^*(\mathbf{y} | \mathbf{x}) = 0$ if $C(\mathbf{x}, \mathbf{y}) = 0$, i.e., q^* only generates sequences satisfying the oracle C .
 3. Given an input \mathbf{x} , $KL(p(\mathbf{y} | \mathbf{x}) || q^*(\mathbf{y} | \mathbf{x}))$ is minimized, i.e., q^* should be as similar to the base model as possible.

辅助模型也是自回归model；辅助模型的结果和指示函数的结果一致；辅助模型与base model尽可能接近；

Before we compute the solution for q^* , given the base model p and oracle C , we first define the token-level guidance as a success rate prediction function $R_p^C(\mathbf{x})$, which defines the probability of the sequence generated by p satisfies the oracle C given the input \mathbf{x} . We similarly define $R_p^C(\mathbf{x}, \mathbf{y}_{\leq i})$ as the probability of success given input \mathbf{x} and prefix $\mathbf{y}_{<i}$. By definition, we have

$$\begin{aligned} R_p^C(\mathbf{x}) &= \Pr_{\mathbf{y} \sim p(\mathbf{y} | \mathbf{x})} [C(\mathbf{x}, \mathbf{y}) = 1] = \sum_{\mathbf{y} \in \mathcal{Y}} p(\mathbf{y} | \mathbf{x}) C(\mathbf{x}, \mathbf{y}) \\ R_p^C(\mathbf{x}, \mathbf{y}_{\leq i}) &= \Pr_{\mathbf{y} \sim p(\mathbf{y} | \mathbf{x})} [C(\mathbf{x}, \mathbf{y}) = 1 | \mathbf{y}_{<i}] = \sum_{\mathbf{y} \in \mathcal{Y}} p(\mathbf{y} | \mathbf{x}, \mathbf{y}_{<i}) C(\mathbf{x}, \mathbf{y}). \end{aligned} \tag{1}$$

定义两个概率：

- 输入成功率：对于给定输入 x ，通过base model p 得到的结果 y 最终满足指示函数的概率 $R_p^C(x)$;
- 序列成功率：对于给定输入 x 以及部分序列 $y_{<i}$ ，通过base model p 得到结果 y 最终最终满足指示函数的概率 $R_p^C(x, y_{<i})$;

解析解的给出

对于给定的 x ，定义一个sequence-level的分布 Q 满足指示函数引导的分布，所以得到 q^* 的解析解为：

With the function R_p^C , we now derive the closed-form solution of q^* considering conditions 2 and 3 defined in Sec. 3.1. Given input x , we define the feasible sequence-level distribution set Q as

$$Q := \{q \mid \sum_{y: C(x,y)=0} q(y|x) = 0\}, \quad (2)$$

then the sequence-level closed-form solution for q^* is given by

$$q^*(y|x) = \arg \min_{q \in Q} KL(p(y|x) \| q(y|x)) = \frac{p(y|x)C(x,y)}{R_p^C(x)}. \quad (3)$$

为了理解这个式子，论文中没有给出过程或者解释，我这里给一个非常直观的例子：假设输入 x 可以通过 p 均匀分布得到 y_1, y_2, \dots, y_5 ，其中 $C(x, y_1)=1, C(x, y_2)=1$ ，其他都为0；那么 q 相当于将概率分布聚焦于正例之上，而确保负例的输出概率为0（这是一个硬约束）；或者说是一个缩放

$$q^*(y|x) = \frac{p(y|x)}{R_p^C(x)}$$

接下来，把这个概率分布 q 唯一分解为token-level：

$$q^*(y_i|x, y_{<i}) = \frac{R_p^C(x, y_{\leq i})}{R_p^C(x, y_{\leq i-1})} p(y_i|x, y_{<i}). \quad (4)$$

The sequence-level solution q^* is given by

$$q^*(\mathbf{y}|\mathbf{x}) = \frac{p(\mathbf{y}|\mathbf{x})C(\mathbf{x}, \mathbf{y})}{R_p^C(\mathbf{x})}.$$

Now we prove that

$$q^*(y_i|\mathbf{x}, \mathbf{y}_{<i}) = \frac{R_p^C(\mathbf{x}, \mathbf{y}_{\leq i})}{R_p^C(\mathbf{x}, \mathbf{y}_{\leq i-1})} p(y_i|\mathbf{x}, \mathbf{y}_{<i}),$$

is the unique token-level decomposition. On one hand, we verify q^* is a valid decomposition, which can be demonstrated by

$$\begin{aligned} \prod_{i=0}^L q^*(y_i|\mathbf{x}, \mathbf{y}_{<i}) &= \prod_{i=1}^L \frac{R_p^C(\mathbf{x}, \mathbf{y}_{\leq i})}{R_p^C(\mathbf{x}, \mathbf{y}_{\leq i-1})} p(y_i|\mathbf{x}, \mathbf{y}_{<i}) \\ &= \frac{R_p^C(\mathbf{x}, \mathbf{y}_{\leq L})}{R_p^C(\mathbf{x}, \mathbf{y}_{\leq 0})} \prod_{i=0}^L p(y_i|\mathbf{x}, \mathbf{y}_{<i}) \\ &= \frac{C(\mathbf{x}, \mathbf{y})}{R_p^C(\mathbf{x})} p(\mathbf{y}|\mathbf{x}) \\ &= q^*(\mathbf{y}|\mathbf{x}), \end{aligned} \tag{10}$$

together with

$$\sum_{y_i} q^*(y_i|\mathbf{x}, \mathbf{y}_{<i}) = \frac{\sum_{y_i} R_p^C(\mathbf{x}, \mathbf{y}_{\leq i}) p(y_i|\mathbf{x}, \mathbf{y}_{<i})}{R_p^C(\mathbf{x}, \mathbf{y}_{\leq i-1})} = 1 \tag{11}$$

On the other hand, we demonstrate that the decomposition is unique. We generally prove that